# MARCO: Methodology of Agentic Reporting and Composition Orchestration for Academic Documents

**Walter A. Mata-López***

**Facultad de Ingeniería Mecánica y Eléctrica/Universidad de Colima. Carretera Colima-Coquimatlán km. 9, Coquimatlán, Colima; e-mail: wmata@ucol.mx*

**Abstract**: An agentic Human-in-the-Loop (HITL) framework for orchestrating scientific publications is proposed. The system integrates master workflows, modular skills, and governance rules: they extract parametric constraints from the target editorial template, guide large-scale literature curation, orchestrate sequential section drafting, and homologate references, keeping the researcher as epistemic arbiter at every phase. The framework was validated autopoietically: the methodology was used to draft this manuscript under IFAC guidelines (CITCA 2026). Sixteen articles were processed; the researcher acted simultaneously as system architect, direct co-author, and epistemic arbiter, with contributions ranging from the prior design of skills and rules to lexical editing and authorship of foundational passages. Results confirm that rules-based governance prevents factual hallucination, that human contribution is structurally broader than any partial log can capture, and that the framework is agnostic to the target editorial standard.

*Keywords*: agentic artificial intelligence, human-in-the-loop, academic writing, workflows, large language models.

## 1. INTRODUCCIÓN

La integración de los Modelos de Lenguaje de Gran Escala (LLM, por sus siglas en inglés) en la redacción científica, la automatización de las revisiones bibliográficas y la publicación académica está transformando rápidamente los flujos de trabajo de la investigación. El enfoque *Human-In-The-Loop* (HITL), en el que los LLM prestan asistencia, pero no sustituyen por completo la experiencia humana, son cada vez más habituales y ofrecen una mayor eficiencia en tareas como la selección de bibliografía, la extracción de datos, la redacción de manuscritos y la revisión por pares. Los flujos de trabajo que coordinan múltiples agentes de IA Generativa (IAG) o LLM modulares para automatizar procesos complejos como las revisiones sistemáticas o incluso ciclos de investigación completos, están surgiendo como un nuevo paradigma. Si bien estas tecnologías pueden reducir drásticamente la carga de trabajo manual y acelerar la síntesis de la evidencia, también plantean retos relacionados con la precisión, la transparencia, el uso ético y el riesgo de una dependencia excesiva del contenido generado por la IAG. La bibliografía destaca tanto el potencial como los riesgos de estas innovaciones: los LLM pueden igualar o superar el rendimiento humano en determinadas tareas de revisión bajo condiciones específicas, pero siguen requiriendo una supervisión humana rigurosa para garantizar la calidad y la integridad. A medida que su adopción crece en todas las disciplinas, es preponderante establecer directrices claras para el uso responsable y la evaluación continua de los sistemas agénticos a fin de mantener la confianza en la comunicación científica.

Esta tecnología ha derivado recientemente en la búsqueda de la automatización total del proceso de descubrimiento e iteración científica. Sistemas multi-agente contemporáneos, como The AI Scientist (Lu et al., 2024), CycleResearcher (Weng et al., 2025) o el framework de la Universidad de Tampere (Sami et al., 2025), demuestran la viabilidad de delegar con tecnología de IAG, procesos que abarcan desde el planteamiento de una hipótesis hasta la evaluación simulada por pares y redacción de manuscritos a un costo mínimo. Paralelamente, en el dominio de las Revisiones Sistemáticas de Literatura (SLR, por sus siglas en inglés), la aparición de infraestructuras interconectadas como LatteReview (Rouzrokh et al., 2024) y PROMPTHEUS (Torres et al., 2025) prometen mitigar el severo cuello de botella provocado por el crecimiento exponencial de la literatura científica, asumiendo tareas operativas críticas como la extracción de datos y el escrutinio automatizado de títulos y resúmenes (Ye et al., 2024; Dennstädt et al., 2024).

Sin embargo, someter la producción intelectual enteramente a una delegación no supervisada provoca una peligrosa homogeneización del discurso e imprecisión fenomenológica. La literatura advierte que los modelos, a pesar de sus impresionantes tasas de recuperación y abstracción, fracasan al momento de discriminar sesgos metodológicos complejos en estudios contradictorios, el cual es un razonamiento que sigue requiriendo el criterio cognitivo humano (Khraisha et al., 2024). Confiar a ciegas en las capacidades narrativas de un agente no solo desvincula el análisis humano de la proximidad con el objeto de estudio, sino que induce el llamado *automation bias* o sesgo de automatización (Drori & Te'eni, 2024; Silva et al., 2025). Ante este problema, se hace imperativo formalizar un ecosistema donde la orquestación del conocimiento combine el vasto poder computacional de la parametrización de bases de datos con el rigor epistemológico que solo el experto humano provee (Malik & Terzidis, 2025).

Para que este balance sistémico HITL rinda frutos, el orquestador artificial debe ser disociado de respuestas creativas "crudas" e integrarse bajo infraestructuras estrictas de validación. Métodos de ajuste iterativo propuestos mediante Ajuste Fino con Eficiencia en los Parámetros (PEFT, por sus siglñas en inglés) por Susnjak et al. (2024), o controles de versiones asimétricos sobre redacción asistida (Pividori & Greene, 2024), sugieren que la IA rinde mejor cuando opera bajo flujos de trabajo agénticos que restringen o limitan la acción del modelo a tareas discretas y auditables.

Como respuesta a este desafío técnico y conceptual, el presente artículo propone y documenta MARCO (Metodología Agéntica para la Redacción y Composición Orquestada): un framework de orquestación HITL de aplicación universal para la producción de documentos académicos. MARCO no está concebido exclusivamente para artículos de congreso: su flujo de cuatro fases: 1) parametrización del destino, 2) curaduría literaria, 3) redacción modular y 4) ensamblaje; es estructuralmente invariante para tesis, ensayos, resúmenes ejecutivos, reportes técnicos y propuestas de investigación. Lo que varía entre tipos de documento es únicamente la configuración de las habilidades (*skills*) y las restricciones paramétricas del destino, no la arquitectura del proceso. Yendo un paso más allá de una revisión teórica, este manuscrito opera como un experimento metacognitivo vivo: la metodología formulada fue utilizada (de manera autopoiética) para planificar, esquematizar, curar literatura y redactar este mismo documento, adaptándose a la parametrización de formato de la conferencia CITCA 2026. La Sección 2 fundamenta los conceptos de agentes, *skills*, reglas (*rules*) y flujos de trabajo (*workflows*); la Sección 3 detalla cada paso de MARCO como guía replicable, incluyendo recomendaciones de implementación; la Sección 4 reporta los resultados del experimento metacognitivo; y la Sección 5 formula las conclusiones y limitaciones.

## 2. MARCO TEÓRICO

### *2.1 De la automatización total a la orquestación HITL*

La adopción de la Inteligencia Artificial en la producción académica se ha polarizado recientemente en dos extremos conceptuales, dejando un vacío metódico que justifica la arquitectura propuesta. En un extremo se encuentra la automatización total o delegación no supervisada: sistemas que intentan marginar al investigador de la ecuación epistémica. Plataformas de frontera como The AI Scientist (Lu et al., 2024) aspiran a ejecutar el ciclo completo de descubrimiento, experimentación y redacción de artículos científicos de forma autónoma. Si bien suponen un hito de ingeniería, delegar la abstracción fenomenológica en algoritmos estadísticos fomenta la alucinación, carece de anclaje contextual tácito y compromete severamente la integridad y responsabilidad autoral.

En el extremo opuesto se ubica el paradigma del prompting conversacional: el uso de chatbots operando interacciones aisladas (Ahn, 2024). Aunque este enfoque devuelve el control al usuario, adolece de memoria sistemática, es incapaz de ejecutar instrucciones paramétricas complejas y somete al texto al sesgo de "estilo IA" genérico. Paralelamente en el mundo de los frameworks de desarrollo, librerías multipropósito como AutoGen (Wu et al., 2023) o sistemas enciclopédicos como STORM (Shao et al., 2024) resuelven la orquestación técnica, pero están diseñados para despliegues de programación o resúmenes tipo Wikipedia, careciendo de formalidad metodológica institucional.

Es precisamente en medio de esta dicotomía donde se hace imperativa la orquestación metodológica HITL (Human-in-the-Loop). Al dotar a los modelos base (Claude, Gemini) de una gobernanza rígida, el agente no actúa como "creador" ni como un simple "chat", sino como un ecosistema de instrumentación (Baek et al., 2024). Plataformas instrumentales como Antigravity (Google DeepMind) permiten instanciar esta separación entre el motor cognitivo (el LLM) y la gobernanza del entorno, asegurando que sea el investigador quien dicte el ensamblaje científico paso a paso bajo control auditable.

### *2.2 Flujos de trabajo agénticos (workflow)*

Un *workflow* es una especificación formal y secuencial de las etapas que un agente debe ejecutar para alcanzar un objetivo de producción complejo. En el contexto de la producción académica, un *workflow* maestro actúa como una metaestructura que orquesta subsecuentemente la ingesta de literatura, la revisión por secciones, el formateo bibliográfico y el ensamblaje editorial final. Su diferencia con una lista de instrucciones vaga reside en su adherencia a puntos de control explícitos (*checkpoints*) que requieren confirmación del humano antes de avanzar a la siguiente fase, garantizando que se mantenga el arbitraje epistémico en todo momento. MARCO implementa este principio mediante un *workflow* maestro único (*/write-article*) que actúa como punto de entrada invariante para cualquier tipo de documento académico, ya sea este artículo, tesis, ensayo o reporte técnico, adaptando las fases de ejecución a las restricciones paramétricas del destino sin alterar la arquitectura de orquestación.

La importancia de este diseño ha sido constatada empíricamente: flujos de trabajo semi-automatizados que mantienen al humano como punto de control en etapas críticas de inclusión/exclusión logran una precisión superior a la de los modelos operando en modo totalmente autónomo (Ye et al., 2024). El *workflow* no solo disciplina o regula al agente, sino que estructura el conocimiento al obligar a declarar explícitamente los criterios antes de cada paso de automatización.

### *2.3 Skills (habilidades) y rules (reglas): modularidad y gobernanza del sistema*

Los *skills* (habilidades modulares especializadas) son unidades funcionales reutilizables que encapsulan una tarea específica del proceso editorial: revisar un artículo en especial, procesar una carpeta de literatura en lote, redactar una sección del manuscrito u homologar referencias bibliográficas. Cada *skill* opera bajo instrucciones propias que lo especializan, pero hereda las restricciones globales del sistema. La Figura 1 ilustra la relación jerárquica entre estas capas, y la Tabla 1 detalla el catálogo de *skills* con sus funciones, insumos y productos asociados.

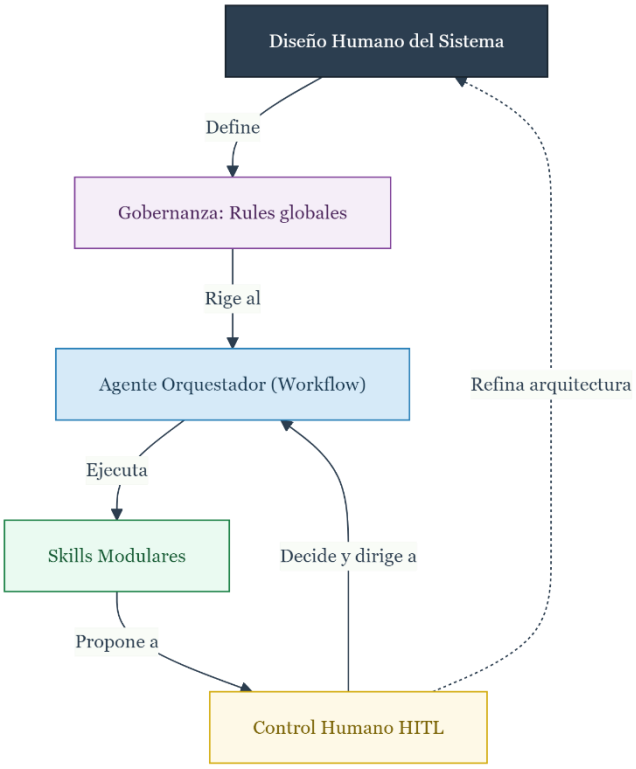


Figura 1. Arquitectura del ecosistema agéntico. Relación jerárquica entre el diseño del sistema, la gobernanza, el agente orquestador y el factor humano HITL. La línea punteada evidencia el rasgo autopoiético de MARCO: el refinamiento iterativo crítico donde se evalúan las salidas del LLM para re-calibrar la arquitectura (*Rules*, *Skills*, *Workflows*).

**Tabla 1. Catálogo de *skills*: función, insumos requeridos y productos generados**

| *Skill* | Función | Insumo requerido | Producto |
|---|---|---|---|
| Batch Review Papers | Procesamiento masivo de literatura | Carpeta con PDFs | Síntesis individual + consolidado temático |
| Review Paper | Análisis singular de un artículo | PDF individual | Ficha de síntesis (APA/IEEE/ Vancouver) |
| Draft Introduction | Redacción de la Introducción | Consolidado literario + hipótesis directrices | Borrador con citas integradas |
| Draft Method | Redacción de la Metodología | Descripción base del diseño | Borrador estructurado según plantilla |
| Draft Results | Redacción de Resultados | Datos u observaciones primarias | Borrador con llamadas a tablas y figuras |
| Draft Discussion | Redacción de la Discusión | Resultados + Marco Teórico | Borrador con contraste literatura–hallazgos |
| Draft Conclusions | Redacción de Conclusiones | Discusión validada | Borrador con aportaciones y limitaciones |
| Draft Abstract | Redacción del Resumen | Cuerpo completo del manuscrito | Resumen al límite exacto de palabras |
| Format References | Homologación bibliográfica | Lista de citas en el texto | Referencias formateadas según norma activa |

Estas restricciones globales se articulan mediante *rules* (reglas de gobernanza del sistema): directivas persistentes que rigen el comportamiento del agente en todas sus interacciones, con independencia del *skill* activo. En el contexto académico, las *rules* son el mecanismo que previene las patologías más frecuentes de la IA generativa: la alucinación de datos, el lenguaje críptico o artificialmente exagerado, y la invención de referencias (Scherbakov et al., 2025). Una *rule* puede especificar, por ejemplo, que el agente debe basar exclusivamente sus afirmaciones en los documentos suministrados como contexto, abstenerse de inferir datos no presentes en el corpus, y respetar el estilo de citación definido por la plantilla activa. La combinación de *skills* modulares y *rules* globales produce un sistema que es, simultáneamente, flexible en su alcance y rígido en su integridad epistémica.

### *2.4 Plantillas editoriales como restricciones paramétricas*

Las normativas de publicación de revistas y congresos (IEEE, APA, IFAC, Vancouver) pueden conceptualizarse, desde la perspectiva del sistema agéntico, como restricciones paramétricas: límites operativos que definen el espacio de soluciones válidas para el manuscrito. Estas restricciones abarcan la extensión máxima (número de páginas o palabras), la jerarquía de secciones obligatorias, el formato de la lista de referencias, el estilo tipográfico para tablas y figuras, y los requerimientos del resumen (palabras clave, estructura IMRaD o similar).

La ventaja del enfoque agéntico es que este universo de restricciones puede ser extraído, analizado e incorporado como contexto activo por el agente desde el inicio del proceso, mediante la lectura directa del archivo de plantilla, y mantenido durante toda la sesión de redacción. Este paso, que en flujos de trabajo convencionales implica relecturas manuales repetidas y errores de formato costosos en tiempo, queda automatizado como la Fase Inicial del *workflow* maestro, antes de haber escrito una sola palabra de forma

manual. Ello garantiza coherencia paramétrica desde el primer archivo generado hasta el ensamblaje del manuscrito final.

## 3. METODOLOGÍA

El *framework* propuesto estructura el ciclo de producción académica en cuatro fases secuenciales y un eje transversal de gobernanza. La secuencia es invariante: ninguna fase de escritura puede iniciarse sin que haya concluido la precedente, y se establece un punto de control humano explícito en cada transición. La Figura 2 sintetiza el flujo general del *pipeline*.

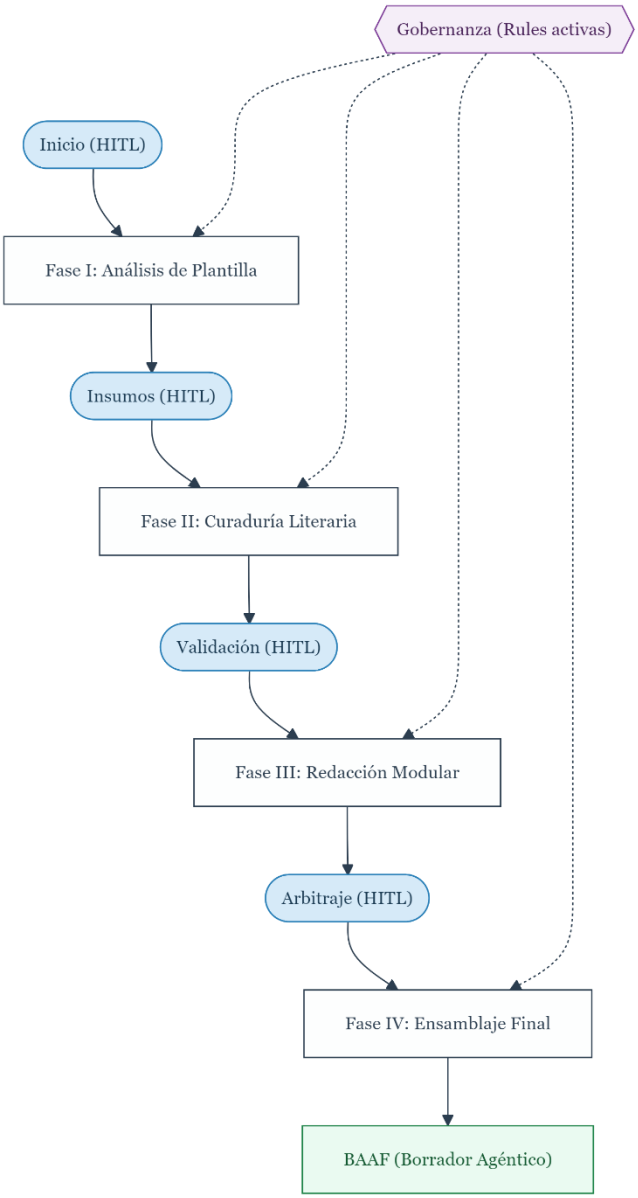


Figura 2. *Pipeline* MARCO: de la plantilla editorial al manuscrito final. Flujo del workflow maestro de MARCO con sus 4 fases secuenciales y el eje de gobernanza, culminando en la producción del Borrador Agéntico (BAAF) previo a la Fase V humana de curaduría final.

El *framework* descrito en este artículo no es dependiente de un modelo o plataforma específicos; no obstante, el experimento reportado en la Sección 4 se ejecutó sobre un entorno tecnológico concreto que conviene declarar para garantizar la reproducibilidad. El entorno agéntico utilizado fue Antigravity (Google DeepMind), un entorno de desarrollo integrado (IDE) que provee la capa de orquestación sobre modelos base. Los modelos subyacentes empleados durante la sesión incluyeron Gemini 3.1 Pro (High) (Google DeepMind), así como Claude Sonnet y Claude Pro (Anthropic), seleccionados de forma híbrida en distintas fases según la demanda cognitiva o técnica de cada tarea. El sistema operativo anfitrión fue Windows 11, y el espacio de trabajo fue gestionado como un repositorio local de archivos Markdown estructurados.

Los *workflows*, *skills* y *rules* se definieron como archivos de configuración propios del entorno de trabajo (directorio .agents/), indepedientes del modelo subyacente. Esto confirma la portabilidad del framework: la arquitectura de orquestación puede reimplementarse sobre entornos similares como Cursor, Windsurf o cualquier IDE con capacidades agénticas y ejecución de herramientas, sustituyendo el modelo base según disponibilidad y preferencia.

### *3.1 Fase I: Análisis de la plantilla y generación del esqueleto*

Figura 3. *Diagrama de flujo de la Fase I (parametrización).*

El proceso no comienza con la redacción, sino con un acto de intervención explícita (véase la Figura 3): la invocación del *workflow* maestro (*/write-article*). Este comando, diseñado previamente como un archivo de configuración del entorno agéntico, es el punto cero del ciclo: su activación carga las *rules* globales, establece la secuencia de fases y solicita los dos insumos iniciales imprescindibles: la ruta del archivo de plantilla editorial y la carpeta del corpus de literatura. Sin estos dos datos provistos por el humano, el sistema no puede avanzar (primer punto de control HITL, previo a cualquier generación de texto). A partir de esa activación, el agente procede a la parametrización del entorno editorial destino mediante las siguientes operaciones:

1. **Extracción de restricciones paramétricas.** El agente lee el documento y extrae las directrices editoriales críticas: extensión máxima del manuscrito, sistema de citación requerido (APA, IEEE, IFAC, etc.), estructura obligatoria de secciones, formato del resumen (límite de palabras, campos requeridos) y normativas para tablas y figuras.

2. **Generación del esqueleto modular.** A partir de las secciones identificadas, el agente genera automáticamente los archivos .md correspondientes al manuscrito (uno por sección), insertando en la cabecera de cada archivo las restricciones extraídas como recordatorio activo durante la redacción posterior.

3. Instrucción para recopilación. Una vez creado el esqueleto, el agente emite un informe de requisitos, indicando el corpus de literatura que debe recopilarse (tipología de fuentes, idiomas aceptados, rango de

años) y cualquier dato empírico primario que deberá proveer para las secciones de método y resultados. Este paso materializa el segundo punto de control HITL del proceso: el agente espera la entrega activa de los insumos antes de avanzar.

### *3.2 Eje transversal: Gobernanza por rules*

De forma paralela a todas las fases, el comportamiento del agente está gobernado por un archivo de *rules* (reglas de gobernanza del sistema) que actúa como sistema normativo persistente. Estas directrices cumplen tres funciones críticas:

- **Control de veracidad:** El agente está instruido para derivar sus afirmaciones exclusiva y trazablemente de los documentos proporcionados como contexto. Cualquier afirmación que no pueda respaldarse con una cita del corpus disponible debe ser señalada como inferencia o suprimida.
- **Control de estilo:** Las *rules* proscriben el lenguaje propio de la IA generativa no supervisada: formulaciones autoreferenciales, generalizaciones vacías, muletillas típicas del discurso asistido ("es importante destacar", "en conclusión", "cabe señalar") y cualquier recurso retórico que comprometa la neutralidad del texto académico.
- **Control de formato:** El agente mantiene activas las restricciones paramétricas extraídas en la Fase I, garantizando que la numeración de figuras, el estilo de citas y la longitud de cada sección se ajusten en tiempo real a la normativa de la plantilla activa.

Es importante aclarar que las *rules*, los *skills* y los *workflows* del sistema no fueron generados por la IA (y no deben ser): fueron diseñados, redactados y refinados con anterioridad a la sesión de escritura, como producto acumulado de la experiencia metodológica. Este trabajo de arquitectura del sistema (invisible en el producto final) constituye una inversión intelectual previa determinante para la calidad del proceso.

#### *3.2.1 Tipología de la Contribución Humana en el Ciclo HITL*

La participación humana en la metodología no se limita a revisar borradores generados por el agente. El ciclo HITL comprende cinco modalidades de contribución cualitativamente distintas:

1. **Diseño del sistema (exclusivo humano).** Antes de iniciar cualquier sesión, se definen los *workflows*, *skills* y *rules* del entorno agéntico a partir de su conocimiento disciplinar. Esta arquitectura determina la calidad del proceso de forma más determinante que el modelo base utilizado.
2. **Redacción autónoma.** Se escriben directamente fragmentos del manuscrito (argumentos centrales, hipótesis, párrafos fundacionales) que el agente posteriormente expande, referencia o complementa. El borrador manual actúa como ancla epistémica que el agente no puede ni debe reemplazar.
3. **Orquestación de prompts.** Se formulan instrucciones precisas al agente para cada tarea, ajustando el nivel de detalle, el alcance temático y las fuentes autorizadas por sección. La calidad del prompt determina directamente la pertinencia de la salida (output) generada.
4. **Revisión iterativa profunda.** El ciclo de revisión no se reduce a intervenciones puntuales: se lee párrafo a párrafo, detecta términos fuera del registro académico del artículo en cuestión, identifica inconsistencias de voz, corrige unidades de significado que el agente desplaza semánticamente, y regresa en múltiples rondas sobre el mismo texto antes de validarlo. Este proceso puede acumular horas de trabajo en una sesión de redacción.
5. **Arbitraje epistémico.** Las decisiones sobre qué incluir, qué omitir, cómo jerarquizar los argumentos y qué posición adoptar ante la literatura son responsabilidad exclusiva del factor humano. El agente propone; la decisión final recae en la evaluación consciente.

### *3.3 Fase II: Curaduría literaria masiva*

Figura 4. *Diagrama de flujo de la Fase II (curaduría literaria).*

Una vez que se deposita el corpus de documentos fuente, como se ilustra en la Figura 4 (artículos recopilados en formato PDF), se activa el *skill* de revisión masiva (*Batch Review Papers*). Este *skill* opera de forma sistemática sobre cada documento del directorio:

1. Extrae el texto de las páginas de apertura y cierre de cada PDF, capturando el resumen, los objetivos, la metodología declarada y las conclusiones principales.
2. Genera un archivo de síntesis individual para cada documento, estructurado con los campos: referencia bibliográfica, problemática abordada, metodología empleada, hallazgos principales y utilidad estimada para el manuscrito en curso.
3. Produce un consolidado temático del corpus completo, agrupando los documentos por ejes de debate, que servirá de insumo directo para la redacción de la Introducción y el Marco Teórico.

Se revisan y validan los resúmenes generados (segundo punto de control HITL), corrigiendo posibles inexactitudes de extracción antes de que el contenido sea incorporado como base argumentativa del texto.

### *3.4 Fase III: Redacción modular secuencial*

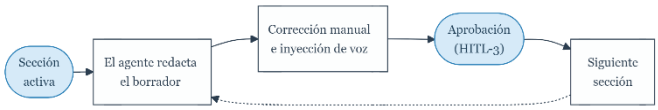


Figura 5. *Diagrama de flujo de la Fase III (redacción modular).*

Con el esqueleto, las *rules* activas y el consolidado literario disponibles, el agente procede a la redacción sección por sección (véase la Figura 5). Cada sección se trabaja mediante un *skill* especializado que conoce su estructura requerida y sus restricciones paramétricas específicas:

- **Introducción y Marco Teórico (Draft Introduction):** El agente integra los resúmenes del corpus, detecta vacíos en la literatura, hila el planteamiento del problema y conecta con los objetivos del estudio. Se aporta el párrafo fundacional o las hipótesis centrales; el agente los expande y referencia.
- **Metodología (Draft Method):** Se describe el diseño del estudio, las herramientas utilizadas y el proceso seguido. El agente estructura esta información bajo el formato requerido por la plantilla, sin añadir interpretaciones que no estén respaldadas por lo declarado.
- **Resultados (Draft Results):** Se proveen los datos, observaciones o evidencias primarias. El agente los presenta de forma narrativa y estructurada, integrando las llamadas a las tablas y figuras según la normativa tipográfica vigente.
- **Discusión y Conclusiones (Draft Discussion, Draft Conclusions):** El agente contrasta los resultados con la literatura del Marco Teórico, identifica convergencias y divergencias, y formula las aportaciones del estudio con el nivel de cautela epistemológica que exige el rigor académico.

En cada sección, se ejerce el rol de árbitro final: revisa, corrige terminología, añade matices y aprueba el contenido antes de avanzar a la siguiente fase (tercer punto de control HITL permanente a lo largo de toda la fase).

### *3.5 Fase IV: Ensamblaje, resumen y homologación bibliográfica*

Figura 6. *Diagrama de flujo de la Fase IV (ensamblaje final).*

Una vez redactadas todas las secciones, se ejecutan tres operaciones de cierre, ilustradas en la Figura 6:

1. **Redacción del resumen (Draft Abstract):** Con el cuerpo completo del manuscrito como contexto, el agente redacta el resumen ajustándose al límite de palabras y a los campos obligatorios extraídos en la Fase I. No se produce ningún resumen antes de que el cuerpo del artículo esté consolidado.
2. **Homologación bibliográfica (Format References):** El agente mapea todas las citas presentes en el texto y genera la lista de referencias en el formato requerido por la plantilla, verificando coherencia entre las citas en texto y las entradas bibliográficas finales.
3. **Revisión de consistencia paramétrica:** El agente realiza una verificación final de congruencia entre el manuscrito ensamblado y las restricciones editoriales de la Fase I: extensión total, número de figuras y tablas, formato del título y la afiliación institucional.

El producto resultante de esta Fase IV es el Borrador Agéntico de Alta Fidelidad (BAAF), el cual consisten en un manuscrito que cumple prácticamente con todas las restricciones paramétricas establecidas en las *rules*, pero que por ningún motivo constituye el documento final. A partir de este documento, la metodología da paso a la última Fase: la curaduría final manual, levada a cabo de manera íntegra fuera del entorno agéntico, dedicada a afinar el tono discursivo, ajustar figuras o valores de tablas manualmente, y consolidar la voz definitiva del manuscrito.

La parametrización de variables específicas de entorno, como la gestión de la ventana de contexto, la asignación de tokens por regla, o la extensibilidad a diseños colaborativos multiautor, escapan al enfoque empírico del presente caso de estudio y constituyen el objeto de futuras ampliaciones teóricas de la metodología.

## 4. RESULTADOS

Esta sección reporta los resultados de la aplicación de la metodología descrita en la Sección 3 a un caso concreto: la redacción del presente manuscrito, adaptado a las directrices de la conferencia CITCA 2026 (plantilla IFAC). El proceso fue simultáneamente el objeto de estudio y el instrumento de producción (lo que constituye su carácter autopoiético), requiriendo una documentación paralela y sistemática en tiempo real de cada iteración significativa entre el agente y la dirección humana.

Para la producción del presente manuscrito empírico, se instanció un ecosistema adaptado específicamente a este proyecto sobre el IDE Antigravity. Una fortaleza de MARCO es que se pueden inyectar *skills* y *rules* genéricos o especializados para ayudar en la estructuración de los datos del proyecto particular. La arquitectura empleada se desglosa en la Tabla 2.

**Tabla 2. Componentes arquitectónicos instanciados para la redacción del proyecto.**

| Componente | Archivo / Nombre | Función Genérica en el Proyecto |
|---|---|---|
| *Workflow* | */write-article* | Metarutina de orquestación central de 4 fases para la elaboración del artículo. |
| *Rules* (Gobernanza) | reglas_escritura.md | Bloqueo activo de superlativos empalagosos, prevención de alucinación bibliográfica y |

| Componente | Archivo / Nombre | Función Genérica en el Proyecto |
|---|---|---|
| | | control del formato “modern print”. |
| *Skills* (Curaduría) | *Batch Review / Review Paper* | Extracción y síntesis masiva de los 16 PDFs de literatura consumidos por el sistema. |
| *Skills* (Redacción) | Draft Introduction... (x5) | Segmentación narrativa de cada capítulo adaptándose a la plantilla (IFAC). |
| *Skills* (Edición) | Format References | Homologación bibliográfica final de todas las citas extraídas. |

Como producto de esta arquitectura iterativa, y tras un ciclo de evaluación continua documentado cualitativamente mediante observación participante, que engloba las múltiples iteraciones, ajustes de formato y refinamientos epistémicos ejecutados de forma manual a lo largo del proceso, el sistema generó el Borrador Agéntico de Alta Fidelidad (BAAF). Este manuscrito sirvió como base estructural estable antes de transitar hacia la curaduría humana definitiva.

*4.1 Resultados de la Fase I: Parametrización del entorno*

El experimento se ejecutó sobre el entorno agéntico Antigravity (Google DeepMind) utilizando Gemini 3.1 Pro (High) (Google DeepMind) en conjunto con Claude Sonnet / Claude Pro (Anthropic) como modelos base, aplicando el framework MARCO (Metodología Agéntica para la Redacción y Composición Orquestada) en su primera validación empírica documentada. El proceso se inició con la invocación explícita del *workflow* maestro */write-article* por vía manual (el acto fundacional que activó la carga de las *rules* globales y estableció la secuencia de fases). Los *workflows*, *skills* y *rules* fueron configurados como archivos locales del directorio *.agents/* del espacio de trabajo, habiendo sido diseñados en sesiones previas. La plantilla editorial de CITCA 2026 (formato IFAC, archivo ifacconf.docx) fue procesada al inicio de la sesión. El agente extrajo las siguientes restricciones paramétricas activas durante todo el ciclo:

- Extensión máxima: 6 páginas en columna doble, fuente Times New Roman 10pt.
- Secciones obligatorias: Resumen (máx. 150 palabras), Introducción, cuerpo del artículo, Conclusiones y Referencias.
- Sistema de citación: formato autor-año (estilo APA), lista alfabética al final.
- Formato de figuras y tablas: título centrado en la parte superior, numeración arábiga consecutiva.

El esqueleto modular fue generado automáticamente en 6 archivos .md independientes, creando el entorno de trabajo que estructuró toda la sesión subsecuente. Cabe precisar que el producto de las fases agénticas no es un documento final compilado en un procesador de texto (ej. Word). El ensamblaje visual final en formato .docx y su maquetación a doble columna se ejecutaron íntegramente fuera del sistema durante la Fase de curaduría humana. A pesar de ello, ninguna decisión fundacional de formateo requirió ser re-evaluada, ya que las restricciones permanecieron activas inyectadas directamente en el código de los archivos del agente.

*4.2 Resultados de la Fase II: Curaduría literaria*

Se proveyó un corpus de 18 artículos científicos en formato PDF, recuperados de bases de datos como arXiv, PubMed, Semantic Scholar y repositorios de acceso abierto. La ejecución del *skill* de revisión masiva procesó la totalidad del corpus mediante un script de extracción de texto, generando:

- 18 síntesis individuales estructuradas por: referencia, problemática, metodología, hallazgos y utilidad proyectada.
- 1 consolidado temático agrupado en 4 ejes de debate: (i) automatización total del ciclo científico; (ii) *frameworks* para revisión sistemática; (iii) imperativo del HITL; (iv) infraestructura y ajuste fino.

Punto de fricción documentado: durante la Fase II, el agente intentó automatizar la descarga del corpus mediante scripts de consulta a las API de arXiv y Semantic Scholar. Ambas solicitudes fueron bloqueadas por los servidores (errores HTTP 429 y 503), evidenciando que la recolección de literatura primaria no es delegable íntegramente a procesos automatizados en entornos de API. La intervención HITL fue determinante: se curó y aprovisionó manualmente el corpus, lo que garantizó su pertinencia y calidad temática.

*4.3 Resultados de la Fase III: Redacción modular y puntos de control HITL*

La documentación de la intervención humana durante esta fase adoptó un enfoque cualitativo de observación participante: se registraron los episodios significativos de toma de decisión, corrección o redirección durante la sesión de escritura. Este enfoque (análogo al registro etnográfico aplicado a procesos cognitivos situados) permite capturar la textura de la intervención humana sin reducirla a métricas cuantitativas que, en el estado actual de la investigación, carecen de instrumentos de medición consensuados. Los ejemplos reportados en la Tabla 3 son instancias representativas seleccionadas por su valor metodológico ilustrativo, no un inventario exhaustivo de todas las microintervenciones producidas durante la sesión.

La redacción de las secciones se ejecutó de forma secuencial. La Tabla 3 sintetiza las principales intervenciones manuales durante los puntos de control HITL.

**Tabla 3. Intervenciones HITL registradas durante la redacción modular del manuscrito.**

| Sección | Tipo de intervención | Corrección aplicada | Hallazgo metodológico |
|---|---|---|---|
| | | | |
| 1 Introducción | Corrección de terminología | "grandes modelos de lenguaje" → "modelos de lenguaje de gran escala" | La voz narrativa debe primar sobre las convenciones generativas del modelo |
| 2. Marco Teórico | Corrección léxica | "constreñimientos" → "restricciones"; "parseado" → "analizado e interpretado"; "ingerido" → "extraído" | El modelo reproduce léxico informal propio del argot de ingeniería de software cuando no está restringido |
| 3. Metodología | Corrección de la arquitectura | Las *rules* se reclasificaron de "fase lineal" a "eje transversal" | El agente tiende a linealizar estructuras cíclicas |
| 1 y 2 | Homogene-ización de terminológía | Definición canónica de *workflows*, *skills* y *rules* con aclaración entre paréntesis (Opción B) | La consistencia terminológica requiere una norma explícita dictada de forma manual antes de que el agente la propague |
| Curaduría | Corrección de alcance | El agente revisó sólo 3 de los 18 PDFs en primera instancia; se apuntó al error interrumpiendo el flujo | La supervisión humana del alcance de los *skills* ejecutados es indispensable |

Los puntos de control HITL no fueron obstáculos al proceso: en todos los casos, la corrección inmediata propagó el ajuste al resto del texto de forma consistente. La estimación de tiempos (Tabla 4) desglosa los minutos invertidos y una muestra cualitativa de las intervenciones registradas hasta alcanzar el Borrador Agéntico de Alta Fidelidad (BAAF). Es importante interpretar este tiempo no como el fin del proceso editorial, sino como el esfuerzo requerido para estructurar la base del documento con un alineamiento paramétrico perfecto. A partir de la generación del BAAF, el manuscrito transitó a la última Fase (fuera del entorno agéntico), donde la curaduría humana requirió múltiples horas de trabajo para redibujar figuras especializadas, inyectar semántica de tablas y afinar la estructura del manuscrito final.

**Tabla 3. Intervenciones HITL registradas durante la redacción modular del manuscrito.**

| Fase / Sección | Producto Resultante | Tiempo estimado | Intervenciones HITL |
|---|---|---|---|
| Fase I: Parametrización | Esqueleto modular | ~10 min | 1 |
| Fase II: Curaduría masiva | Síntesis del corpus | ~15 min | 2 |
| Fase III: Introducción | Borrador §1 | ~20 min | 3 |
| Fase III: Marco Teórico | Borrador §2 | ~15 min | 4 |
| Fase III: Metodología | Borrador §3 | ~25 min | 2 |
| Fase IV: Ensamblaje | Referencias y Resumen | ~15 min | 1 |
| Subtotal (MARCO) | Borrador Agéntico (BAAF) | ~100 min | Múltiples |
| Fase V (Humana) | Manuscrito definitivo | Variable (hrs – días) | Fuera del Sistema agéntico |

El tiempo estimado engloba la revisión cognitiva humana integral de cada salida (lectura profunda, verificación léxica y de formato), no únicamente el tiempo de latencia computacional del agente generativo.

*4.4 Eficacia de la gobernanza por rules*

La capa de *rules* demostró su efectividad en la prevención de las patologías más documentadas de la IAG. En ningún momento el agente incorporó referencias bibliográficas no presentes en el corpus proporcionado, ni adoptó un tono laudatorio o autorreferencial. Las correcciones se concentraron exclusivamente en ajustes de nivel léxico y arquitectónico (no en correcciones de veracidad factual), lo que sugiere que el control de veracidad de las *rules* operó de forma efectiva.

La única excepción notable fue el intento inicial de generar la metodología desde el conocimiento general del modelo, sin consultar los archivos locales de workflow y rules del entorno de trabajo. Esta desviación fue detectada y corregida en el primer punto de control HITL, confirmando que la Fase I de la metodología (leer explícitamente la configuración del entorno antes de operar) no puede omitirse sin degradar la precisión del sistema.

## 5. CONCLUSIONES

El presente artículo propuso, describió y demostró empíricamente MARCO (Metodología Agéntica para la Redacción y Composición Orquestada): una metodología HITL de aplicación universal para la orquestación de documentos académicos. El experimento metacognitivo, utilizar el propio MARCO para redactar el artículo que lo documenta, aportó evidencia funcional sobre su viabilidad y sus límites. De los resultados se derivan las siguientes conclusiones:

1. El paradigma agéntico supera cualitativamente al *prompting* conversacional en la producción académica. La combinación de *workflows* maestros, *skills* modulares y *rules* de gobernanza produce un sistema capaz de mantener coherencia paramétrica, trazabilidad bibliográfica y consistencia estilística a lo largo de un manuscrito completo, capacidades que un LLM en modo conversacional estándar no puede garantizar.

2. Las *rules* son el componente crítico del sistema, no un accesorio. La única desviación grave registrada durante el experimento ocurrió cuando el agente operó sin consultar su configuración de *rules* y *workflow* locales, generando una metodología genérica en lugar de la específica del entorno. Esto confirma que la gobernanza explícita no es opcional: sin ella, el modelo reproduce patrones estadísticos generales en lugar de razonamiento situado.

3. El HITL no es un mecanismo de corrección, sino de dirección epistémica. La muestra de intervenciones documentadas formalmente no respondió a errores de veracidad factual, sino a decisiones de nivel arquitectónico, terminológico y léxico, sumadas a múltiples microiteraciones (por ejemplo, ajustes en diagramas e inyección de nuevas métricas) que requieren de un criterio situado continuo por parte de la dirección del manuscrito. Esto distingue al HITL agéntico del simple "revisar lo que genera la IA": el humano dirige la estructura conceptual del conocimiento; el agente ejecuta su instrumentación.

4. MARCO es generalizable a cualquier normativa editorial y tipo de documento académico. La separación entre la capa de restricciones paramétricas (extraídas de la plantilla en la Fase I) y la capa de redacción (Fases III–IV) garantiza que el sistema sea agnóstico al congreso, revista o tipo de documento destino. La Tabla 2 documenta su aplicabilidad a artículos, tesis, ensayos, reportes técnicos y propuestas de investigación.

5. La recolección de literatura primaria permanece como dominio inalienable de nivel supervisor. El intento de automatizar la descarga del corpus vía API fue bloqueado sistemáticamente por las políticas de los repositorios académicos, confirmando que la curaduría de literatura requiere intervención humana deliberada. El agente puede procesar y sintetizar; no puede sustituir el juicio de pertinencia al seleccionar el corpus base.

### *5.1 Limitaciones*

El experimento se basó en una sola sesión de redacción con dirección humana unitaria, lo que limita la generalización de los tiempos reportados en la Tabla 4. Asimismo, la estimación de tiempos es aproximada y no contempla el tiempo de configuración previa del entorno agéntico (instalación, definición de *rules* y *skills*), que puede ser significativo para investigadores que adopten el sistema por primera vez. La ausencia de un instrumento automatizado de registro de las intervenciones humanas constituye una de las limitaciones del experimento: la documentación se basó en el registro cualitativo de observación participante, por lo que los tiempos y conteos de intervención reportados son estimaciones estructuradas y no métricas extraídas paramétricamente del sistema.

Adicionalmente, se documentó una fricción entre la restricción paramétrica inicial y las iteraciones humanas (Fase V): aunque el agente asimiló la directriz de "extensión máxima de 6 páginas", la curaduría cualitativa y la inyección de argumentación manual expandieron el borrador final hasta alcanzar las 10 páginas de longitud. Lejos de ejecutar un recorte metodológico que mutilara la evidencia, se tomó la decisión epistémica explícita de mantener la extensión de 10 páginas, asumiendo la superación del límite original con el fin de preservar y documentar todo el proceso orquestal de la metodología con rigor. Esta tendencia documentada (la expansión del corpus provocada por el refinamiento HITL que rompe los límites del manuscrito) constituye no solo una limitante paramétrica, sino una prueba del peso cognitivo humano en la fase V. Finalmente, la evaluación de la calidad del manuscrito producido queda pendiente de revisión por pares externa, que constituye el paso de validación definitivo del proceso.

### *5.2 Trabajo futuro*

La arquitectura propuesta puede extenderse en al menos cinco direcciones: (i) la incorporación de un *skill* de evaluación automatizada que simule criterios de revisión por pares, siguiendo el modelo de CycleReviewer (Weng et al., 2025); (ii) el desarrollo de métricas objetivas de calidad para los resúmenes generados por el *Batch Review*, más allá de la validación manual; (iii) la adaptación del framework a flujos de trabajo colaborativos multiautor, donde los puntos de control HITL se distribuyen entre varios investigadores con roles diferenciados; (iv) el diseño de una taxonomía operacionalizable de niveles de agencia humana en documentos co-producidos con IAG, que permita a investigadores, editores y comités de ética declarar con precisión el grado de intervención humana en cada sección de un manuscrito, superando la declaración binaria (uso / no uso) vigente en IEEE, Nature o Elsevier; y (v) el diseño e integración de una Bitácora de Trazabilidad HITL sistemática en futuras iteraciones de la metodología en cuestión: un instrumento de registro parametrizado que capture automáticamente el tiempo real de cada fase, el tipo de intervención y la naturaleza de la decisión humana. Esto

permitiría transformar la observación participante cualitativa de este primer estudio exploratorio en datos duros cuantificables y comparables entre proyectos, dotando al proceso de un nivel de audibilidad aún mayor

REFERENCIAS


Ahn, S. (2024). The transformative impact of large language models on medical writing and publishing: current applications, challenges and future directions. The Korean Journal of Physiology & Pharmacology: Official Journal of the Korean Physiological Society and the Korean Society of Pharmacology, 28, 393 - 401. https://doi.org/10.4196/kjpp.2024.28.5.393.

Baek, J., Jauhar, S., Cucerzan, S., & Hwang, S. (2024). ResearchAgent: Iterative Research Idea Generation over Scientific Literature with Large Language Models. ArXiv, abs/2404.07738. https://doi.org/10.48550/arxiv.2404.07738.

Dennstädt, F., Zink, J., Putora, P., Hastings, J., & Cihoric, N. (2024). Title and abstract screening for literature reviews using large language models: an exploratory study in the biomedical domain. Systematic Reviews, 13. https://doi.org/10.1186/s13643-024-02575-4.

Drori, I., & Te'eni, D. (2024). Human-in-the-Loop AI Reviewing: Feasibility, Opportunities, and Risks. J. Assoc. Inf. Syst., 25, 7. https://doi.org/10.17705/1jais.00867.

Khraisha, Q., Put, S., Kappenberg, J., Warraitch, A., & Hadfield, K. (2023). Can large language models replace humans in systematic reviews? Evaluating GPT-4's efficacy in screening and extracting data from peer-reviewed and grey literature in multiple languages. Research Synthesis Methods, 15, 616 - 626. https://doi.org/10.1002/jrsm.1715.

Lu, C., Lu, C., Lange, R., Foerster, J., Clune, J., & Ha, D. (2024). The AI Scientist: Towards Fully Automated Open-Ended Scientific Discovery. ArXiv, abs/2408.06292. https://doi.org/10.48550/arXiv.2408.06292

Malik, F., & Terzidis, O. (2025). A hybrid framework for creating artificial intelligence-augmented systematic literature reviews. Management Review Quarterly. https://doi.org/10.1007/s11301-025-00522-8.

Pividori, M., & Greene, C. (2023). A publishing infrastructure for AI-assisted academic authoring. bioRxiv. https://doi.org/10.1101/2023.01.21.525030.

Rouzrokh, P., & Shariatnia, M. (2025). LatteReview: A Multi-Agent Framework for Systematic Review Automation Using Large Language Models. ArXiv, abs/2501.05468. https://doi.org/10.48550/arxiv.2501.05468.

Sami, M., Rasheed, Z., Kemell, K., Waseem, M., Kilamo, T., Saari, M., Nguyen-Duc, A., Systä, K., & Abrahamsson, P. (2024). System for systematic literature review using multiple AI agents: Concept and an empirical evaluation. ArXiv, abs/2403.08399. https://doi.org/10.48550/arxiv.2403.08399.

Scherbakov, D., Hubig, N., Jansari, V., Bakumenko, A., & Lenert, L. (2024). The emergence of large language models as tools in literature reviews: a large language model-assisted systematic review. Journal of the American Medical Informatics Association: JAMIA, 32, 1071 - 1086. https://doi.org/10.1093/jamia/ocaf063.

Shao, Y., Jiang Y., Kanell T. A., XU, P., Khattab, O., Lam, M. S. (2024). Assisting in Writing Wikipedia-like Articles From Scratch with Large Language Models. arXiv preprint arXiv:2402.14207. https://doi.org/10.48550/arXiv.2402.14207

Silva, J., Gouveia, R., Zielinski, K., Oliveira, M., Amancio, D., Bruno, O., & Oliveira, O. (2025). AI-Assisted Tools for Scientific Review Writing: Opportunities and Cautions. ACS Applied Materials & Interfaces, 17, 47795 - 47805. https://doi.org/10.1021/acsami.5c08837.

Sušnjak, T., Hwang, P., Reyes, N., Barczak, A., Mcintosh, T., & Ranathunga, S. (2024). Automating Research Synthesis with Domain-Specific Large Language Model Fine-Tuning. ACM Transactions on Knowledge Discovery from Data, 19, 1 - 39. https://doi.org/10.1145/3715964.

Torres, J., Mulligan, C., Jorge, J., & Moreira, C. (2025). PROMPTHEUS: A Human-Centered Pipeline to Streamline Systematic Literature Reviews with Large Language Models. Inf., 16, 420. https://doi.org/10.3390/info16050420.

Weng, Y., Zhu, M., Bao, G., Zhang, H., Wang, J., Zhang, Y., & Yang, L. (2024). CycleResearcher: Improving Automated Research via Automated Review. ArXiv, abs/2411.00816. https://doi.org/10.48550/arxiv.2411.00816.

Wu, Q., Bansal, G., Zhang, J., Wu, Y., Li, B., Zhu, E., Jiang, L., Zhang, X., Zhang, S., Liu, J., Awadallah, A. H., White, R., Burger, D., & Wang, C. (2023). AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation. arXiv preprint arXiv:2308.08155. https://doi.org/10.48550/arXiv.2308.08155

Ye, A., Maiti, A., Schmidt, M., & Pedersen, S. (2024). A Hybrid Semi-Automated Workflow for Systematic and Literature Review Processes with Large Language Model Analysis. Future Internet, 16, 167. https://doi.org/10.3390/fi16050167